Домашнее задание 4

Клиническая аннотация генетических вариантов

Шабалина Лилианна | ФИТ НГУ, 23216 | Набор student_30

Homo sapiens | GRCh38

Исходные данные и статистика

Исследован student_30.vcf: 50 уникальных биаллельных SNV, 16 на хромосоме 21 и 34 на хромосоме 22. Транзиции (A↔G, C↔T): 40; трансверсии: 10; Ti/Tv = 4,00. Это описательная характеристика учебной выборки, а не оценка качества полного экзома или генома.

VCF содержит восемь столбцов: CHROM - хромосома, POS - позиция с нумерацией от 1, ID - исходный rsID, REF/ALT - референсный и альтернативный аллели, QUAL - качество вызова, FILTER - статус фильтров, INFO - дополнительные аннотации. QUAL, FILTER и INFO имеют значение «.» (нет данных); FORMAT, генотипы и сведения об образце отсутствуют.

Методика и выбор транскрипта

Аннотации получены через публичные API: Ensembl VEP release 116, NCBI ClinVar E-utilities и gnomAD GraphQL (dataset gnomad_r4, GRCh38). Настройки сохранены в annotation_settings.json. API gnomAD не возвращает в использованном запросе номер минорной версии, поэтому он не приписывается результатам.

В сводку взято most_severe_consequence, рассчитанное VEP по всем транскриптам. Среди транскриптов с этим последствием приоритет: MANE Select → canonical → protein_coding → лексикографически первый transcript_id. Таким образом, MANE Select выбирается только при равной тяжести. Это собственное правило свёртки, не параметр VEP --pick. Все 1525 транскриптные аннотации и альтернативные последствия сохранены отдельно.

ClinVar проверен двумя поисками: по rsID и по координатам chrpos38. Кандидаты объединены, затем строго сопоставлены GRCh38 + CHROM + POS + REF + ALT. Сохранены germline-классификация, review status и отдельные утверждения. Запись evidence_only означает наличие сведений без клинической классификации и выделена отдельно. gnomAD AF относится к ALT и вычисляется как AC/AN; частоты экзомов и геномов приведены раздельно, без сложения когорт. NA означает недоступное значение; not_found - отсутствие точного совпадения после успешного поиска.

Общий результат

VEP аннотировал все 50 вариантов. В gnomAD r4 найдено 49, не найдено 1; отсутствующим записям присвоено NA, а не нулевая частота. ClinVar: 17 точных совпадений и 33 вариантов без записи для данного аллеля. Неопределённая значимость: 2; evidence_only: 1; конфликтующих агрегированных классификаций не обнаружено. Сводная таблица содержит ровно одну строку на исходный вариант; исходный порядок сохранён.

Число вариантов по наиболее значимому последствию VEP: missense_variant: 20; synonymous_variant: 29; stop_gained: 1.

Разбор трёх вариантов

1. rs115157927 | HIRA | 22:19385577 A>T

VEP: missense_variant, ENST00000263208.5:c.1273T>A; ENSP00000263208.5:p.Ser425Thr, MANE Select NM_003325.4; предсказана замена серина на треонин. AF ALT: экзомы 3.21517e-05; геномы 0.000360973. В ClinVar VCV003525634: Uncertain significance (VUS); review status: criteria provided, single submitter; оценка от 08.10.2024, конкретное заболевание не указано (not specified). SIFT = 0,24 (tolerated), PolyPhen = 0,009 (benign). Вычислительные прогнозы не заменяют клинические доказательства. VUS означает недостаточную определённость, а не доказанную патогенность и не конфликт отправителей; собственная переклассификация не проводилась.

2. rs115663049 | TOP3B | 22:21963972 G>A

VEP: synonymous_variant, ENST00000357179.10:c.1155C>T; ENSP00000349705.5:p.Gly385=, MANE Select NM_001282112.2; глицин сохраняется. AF ALT: экзомы 0.000106122; геномы 0.00125405. В ClinVar VCV004456431 запись присутствует, но имеет статус evidence_only, review status: no classification provided. Клиническая патогенность не классифицирована. В функциональных данных одной SCV описано удержание интрона и изменение криптического донорного сайта сплайсинга по анализу RNA-seq. Такие сведения показывают возможное влияние синонимической замены на обработку РНК, но сами по себе не доказывают причинную связь с заболеванием. Запись сохранена как found/evidence_only, а не как отсутствующая, VUS или Pathogenic.

3. rs115458101 | TMEM50B / IFNGR2 | 21:33432763 G>A

VEP: stop_gained, ENST00001004216.1:c.595C>T; ENSP00000674033.1:p.Arg199Ter на выбранном транскрипте TMEM50B ENST00001004216.1: предсказан преждевременный стоп-кодон. Этот транскрипт не имеет флагов MANE Select/canonical. На MANE Select IFNGR2 ENST00000290219.11 та же замена синонимическая, c.771G>A, p.Ser257=. AF ALT: экзомы 2.25738e-05; геномы 5.91413e-05. В ClinVar VCV000749643 запись описана по IFNGR2: Likely benign; review status: criteria provided, single submitter. Конфликта отправителей нет: различаются контексты транскриптов и тип сведений. HIGH/stop_gained в отдельной изоформе не доказывает клиническую патогенность или потерю функции всего гена. Этот пример показывает ограничение выбора максимально тяжёлого последствия без оценки биологической значимости транскрипта.

Заключение и ограничения

Наиболее интересны HIRA с неопределённой клинической значимостью, TOP3B с функциональными сведениями о сплайсинге при синонимическом последствии и rs115458101, где stop_gained относится к изоформе TMEM50B, а клиническая запись - к синонимической замене IFNGR2. Эти примеры показывают разницу между молекулярным последствием, экспериментальным наблюдением, частотой и клинической классификацией.

Выборка мала, учебная, ограничена двумя хромосомами и известными rsID; она не представляет весь геном. Без генотипов, зиготности, фенотипа, происхождения, семейного анамнеза и качества вызовов невозможно определить причину заболевания или оценить индивидуальный риск. Частоты зависят от состава популяций и покрытия; агрегированные AF не заменяют популяционный анализ. Выбор самого тяжёлого последствия может выделять редкую изоформу, а аннотации и классификации меняются между версиями баз. Отсутствие записи gnomAD r4 не означает отсутствия аллеля в других версиях или популяциях. Отсутствующие интерпретации и evidence_only сохранены явно; собственная ACMG-классификация не проводилась.